# LangChain

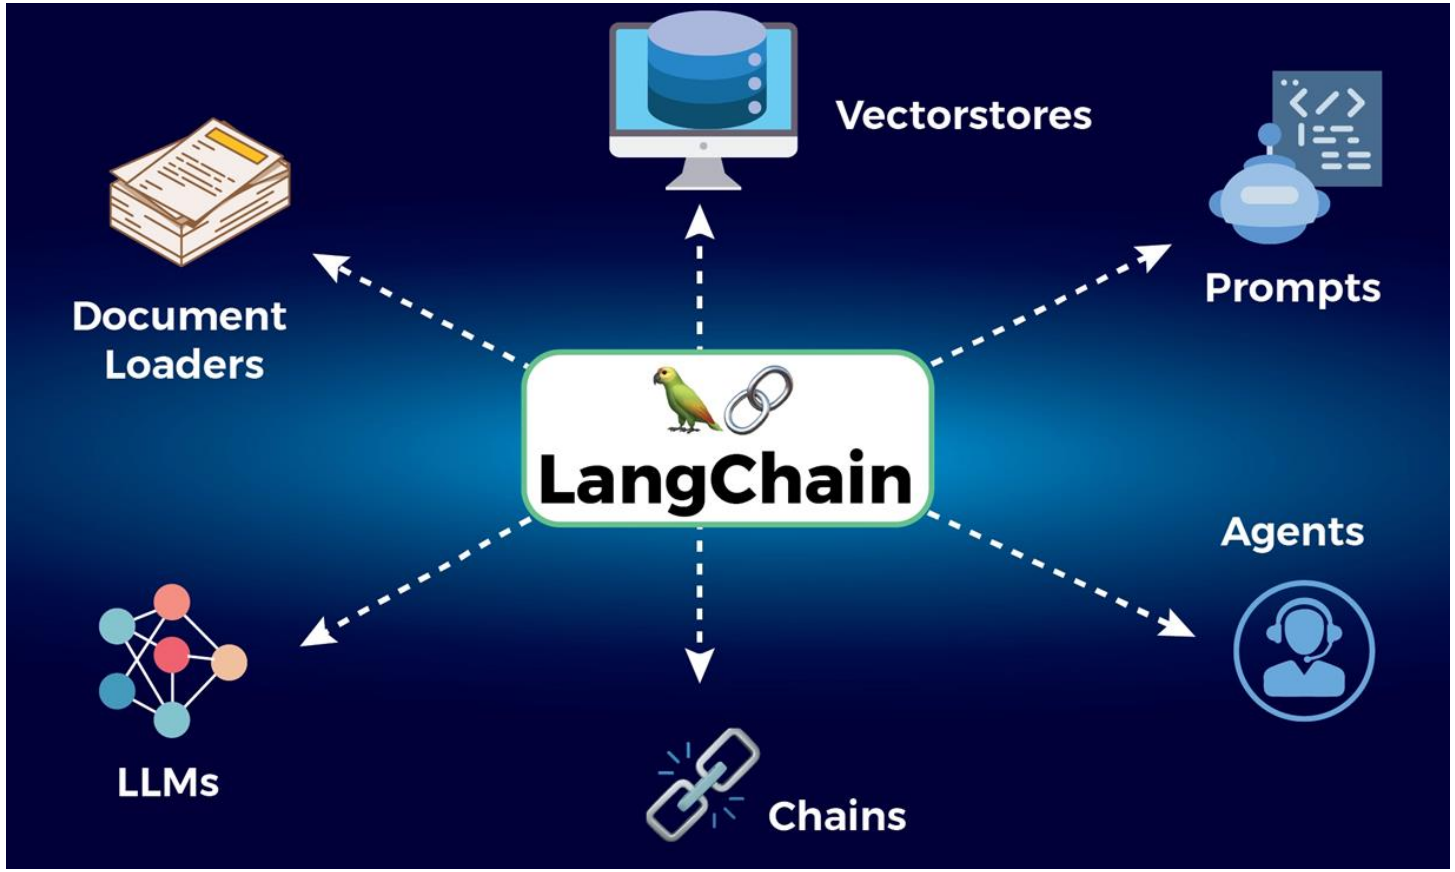


박경규

# LangChain

https://github.com/langchain-ai/langchain

LangChain은 언어 모델로 구동되는 애플리케이션을 개발하기 위한 프레임워크입니다.

다음과 같은 애플리케이션을 지원합니다.

- **문맥 인식**(Are context-aware):
  언어 모델을 문맥 소스(프롬프트 지침, 몇 가지 예시, 응답의 근거가 되는 콘텐츠 등)에 연결합니다.
- **추론**(Reason): 언어 모델에 의존하여 추론(제공된 컨텍스트에 따라 답변하는 방법, 취해야 할 조치 등)

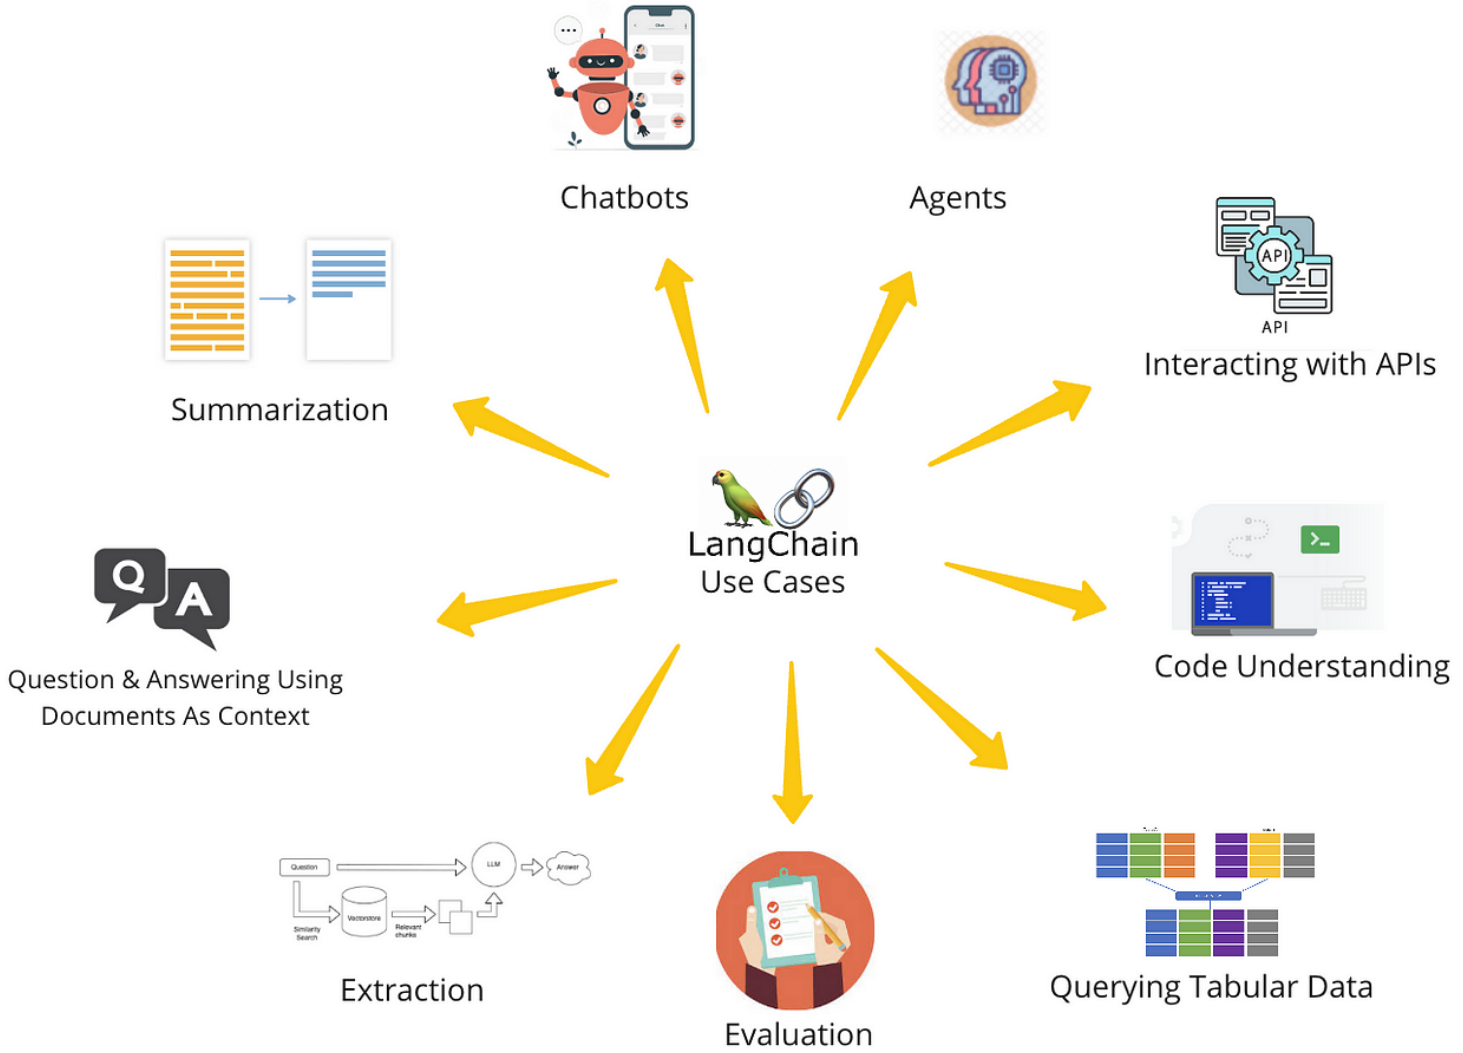

# LangChain 아키텍처

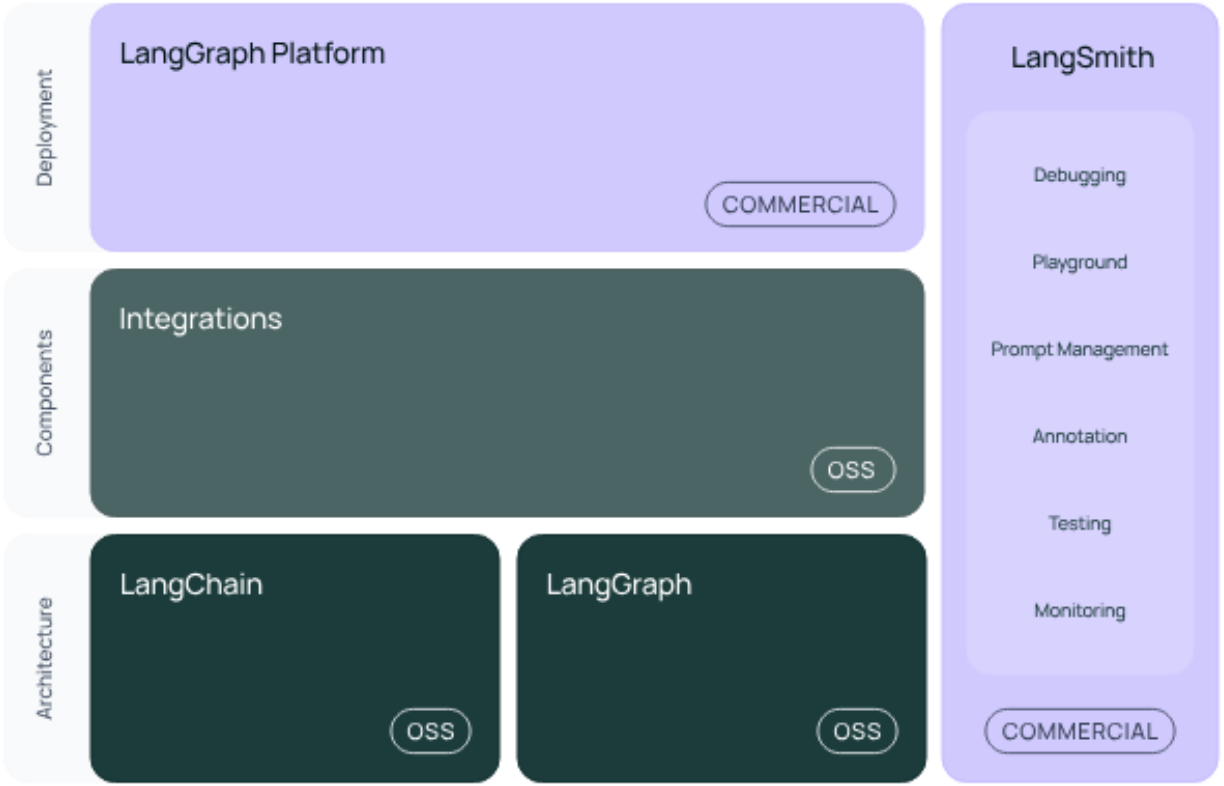


- **Langchain Core**
  - 다양한 컴포넌트에 대한 기본 추상화와 이를 함께 구성하는 방법 포함
  - Chat Model, Vector Store, Tool 등과 같은 핵심 구성 요소 인터페이스 정의

- **LangChain**
  - 애플리케이션 Cognitive 아키텍처를 구성하는 Chain과 Retrieval Strategy 포함

- **Integration Packages**
  - langchain-openai, langchain-anthropic 등
  - https://python.langchain.com/docs/integrations/providers/

- **Langchain Community**
  - LangChain 커뮤니티에서 유지 관리하는 third-party 통합 포함

- **LangGraph**
  - LLM 기반 다중 액터 애플리케이션을 구축하는 것을 목표로 하는 LangChain extension

- **LangServe**
  - LangChain chain을 REST API로 배포하는 패키지

- **LangSmith**
  - LLM 애플리케이션을 디버깅, 테스트, 평가, 모니터링하는 개발자 플랫폼

# LangChain API

## langchain-core

- agents
- beta
- caches
- callbacks
- chat_history
- chat_loaders
- chat_sessions
- document_loaders
- documents
- embeddings
- example_selectors
- exceptions
- globals
- indexing
- language_models
- load
- messages
- output_parsers
- outputs
- prompt_values
- prompts
- rate_limiters
- retrievers
- runnables
- stores
- structured_query
- sys_info
- tools
- tracers
- utils
- **vectorstores**

## langchain

- agents
- callbacks
- chains
- chat_models
- embeddings
- evaluation
- globals
- hub
- indexes
- memory
- model_laboratory
- output_parsers
- retrievers
- runnables
- smith
- storage

## langchain-community

- adapters
- agent_toolkits
- agents
- cache
- callbacks
- chains
- chat_loaders
- chat_message_histories
- chat_models
- cross_encoders
- docstore
- document_compressors
- document_loaders
- document_transformers
- embeddings
- example_selectors
- graph_vectorstores
- graphs
- indexes
- llms
- memory
- output_parsers
- query_constructors
- retrievers
- storage
- tools
- utilities
- utils
- vectorstores

https://python.langchain.com/api_reference/core/index.html

# Provider Integration

| Provider | Package | Downloads | Latest | JS |
|---|---|---|---|---|
| OpenAI | langchain-openai | 12M/month | v0.3.9 | ✅ |
| Google VertexAI | langchain-google-vertexai | 12M/month | v2.0.16 | ✅ |
| Google Community | langchain-google-community | 4.7M/month | v2.0.7 | ❌ |
| AWS | langchain-aws | 2.2M/month | v0.2.17 | ✅ |
| Anthropic | langchain-anthropic | 2.1M/month | v0.3.10 | ✅ |
| Google Generative AI | langchain-google-genai | 1.4M/month | v2.1.1 | ✅ |
| Ollama | langchain-ollama | 920k/month | v0.3.0 | ✅ |
| Cohere | langchain-cohere | 814k/month | v0.4.3 | ✅ |
| PowerScale RAG Connector | powerscale-rag-connector | 129/month | v1.0.9 | ❌ |
| Modelscope | langchain-modelscope | 124/month | v0.1.1 | ❌ |
| Pull Md | langchain-pull-md | 113/month | v0.1.1 | ❌ |
| Fmp Data | langchain-fmp-data | 101/month | v0.1.0 | ❌ |
| Tilores | tilores-langchain | 82/month | v0.2.0 | ❌ |
| Oceanbase | langchain-oceanbase | 83/month | v0.2.0 | ❌ |
| Pipeshift | langchain-pipeshift | 80/month | v0.1.1 | ❌ |
| Lindorm Integration | langchain-lindorm-integration | 72/month | v0.1.1 | ❌ |
| Naver | langchain-naver-community | 111/month | v0.1.1 | ❌ |

https://python.langchain.com/docs/integrations/providers/

# LangChain 모듈

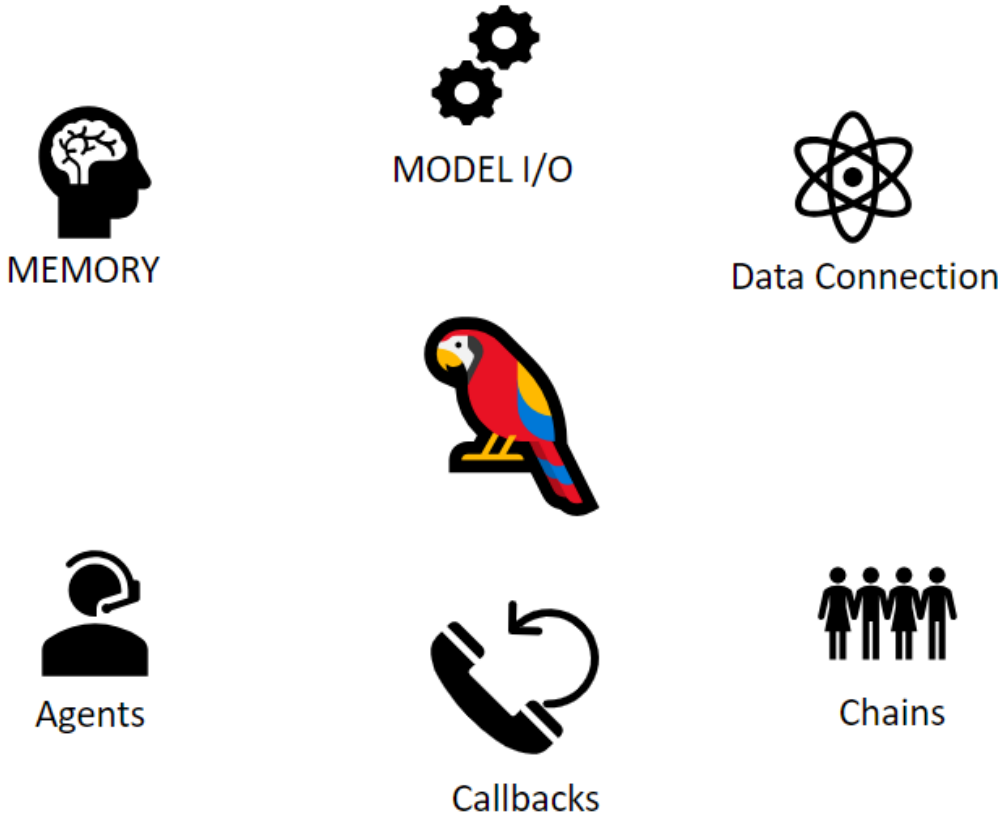


- Model I/O : 언어 모델과의 인터페이스
- Data Connection : 데이터와의  인터페이스
- Chains : 호출 시퀀스 구축
- Callbacks : 체인의 중간 단계를 기록 및 스트리밍
- Agents : 상위 지시문이 주어지면 체인이  사용할 도구(Tool)을 선택할 수 있도록 함
- Memory : 체인 실행 간에 애플리케이션 상태 유지

# Model I/O

모든 언어모델 애플리케이션의 핵심 요소는 Model입니다.
Model I/O는 LangChain이 모든 언어모델과 인터페이스 할 수 있는 빌딩 블록을 제공합니다.

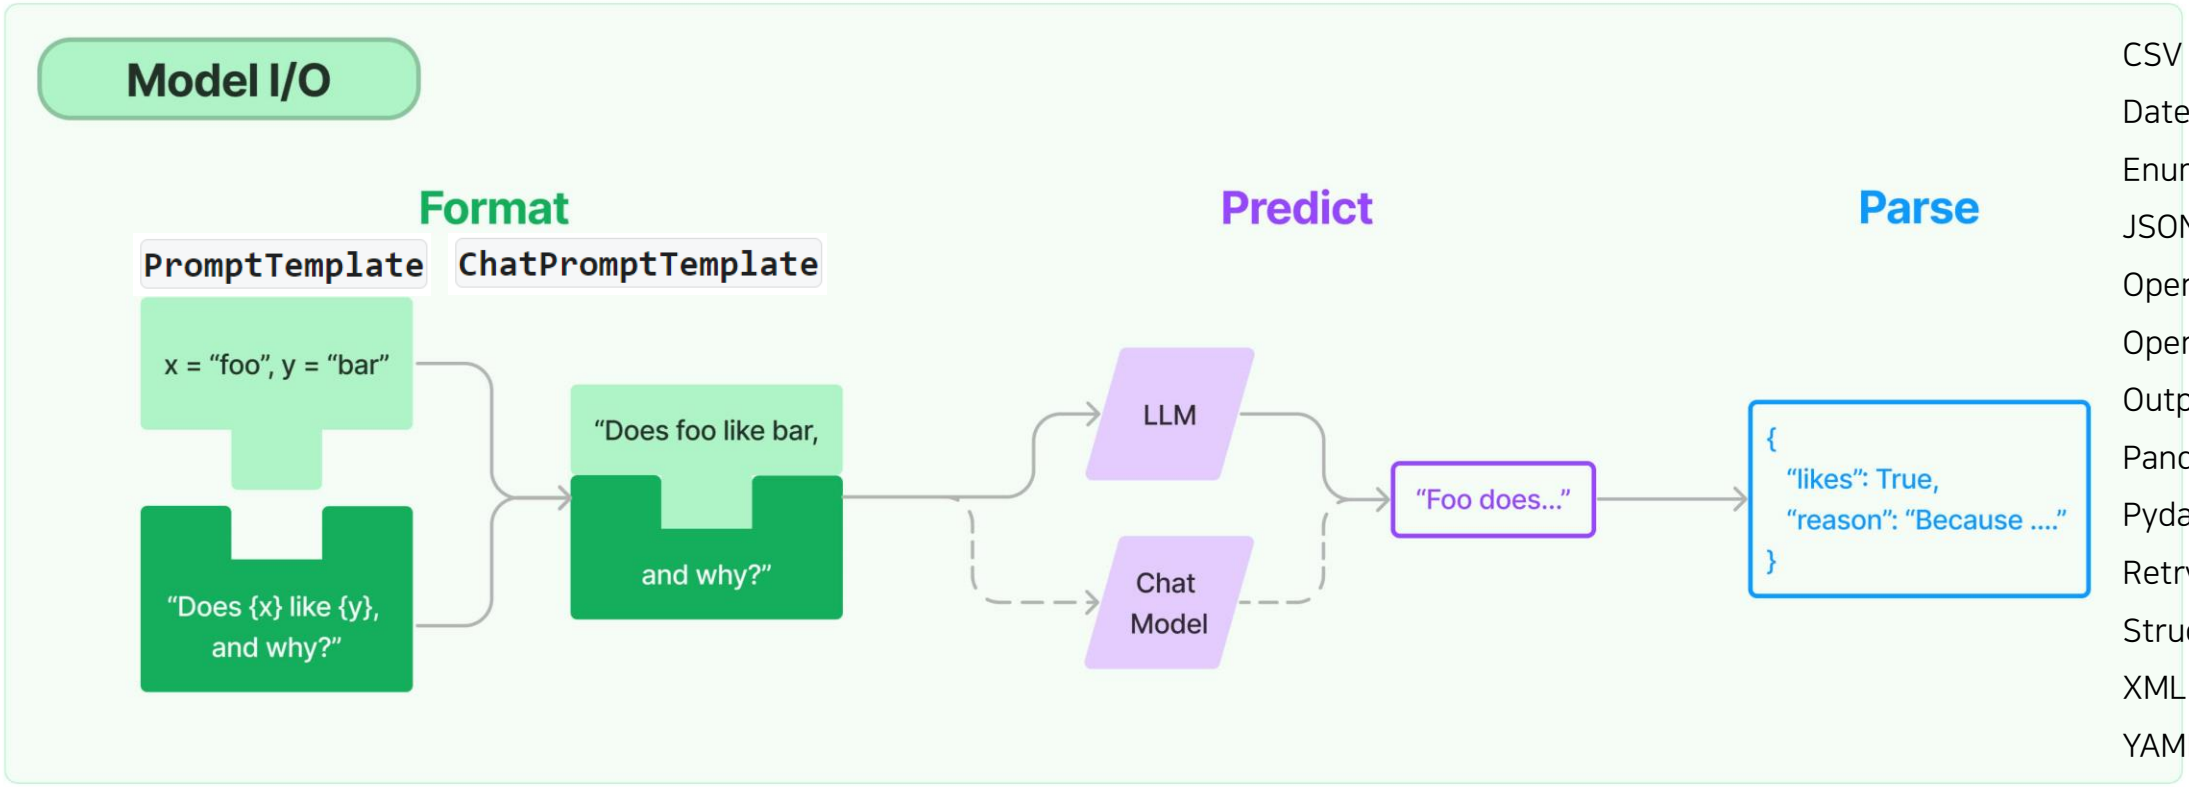


- CSV parser
- Datetime parser
- Enum parser
- JSON parser
- OpenAI Functions
- OpenAI Tools
- Output-fixing parser
- Pandas DataFrame Parser
- Pydantic parser
- Retry parser
- Structured output parser
- XML parser
- YAML parser

This is documentation for LangChain v0.1, which is no longer actively maintained. Check out the docs for the latest version here.

https://python.langchain.com/v0.1/docs/modules/model_io/

# Retrieval

많은 LLM 애플리케이션에는 모델 학습 세트의 일부가 아닌 사용자 데이터가 필요합니다.
이를 달성하는 주요 방법은 검색 증강 생성(RAG, Retrieval-Augmented Generation)을 사용하는 것입니다.
LangChain은 RAG 애플리케이션을 위한 모든 빌딩 블록을 제공합니다.

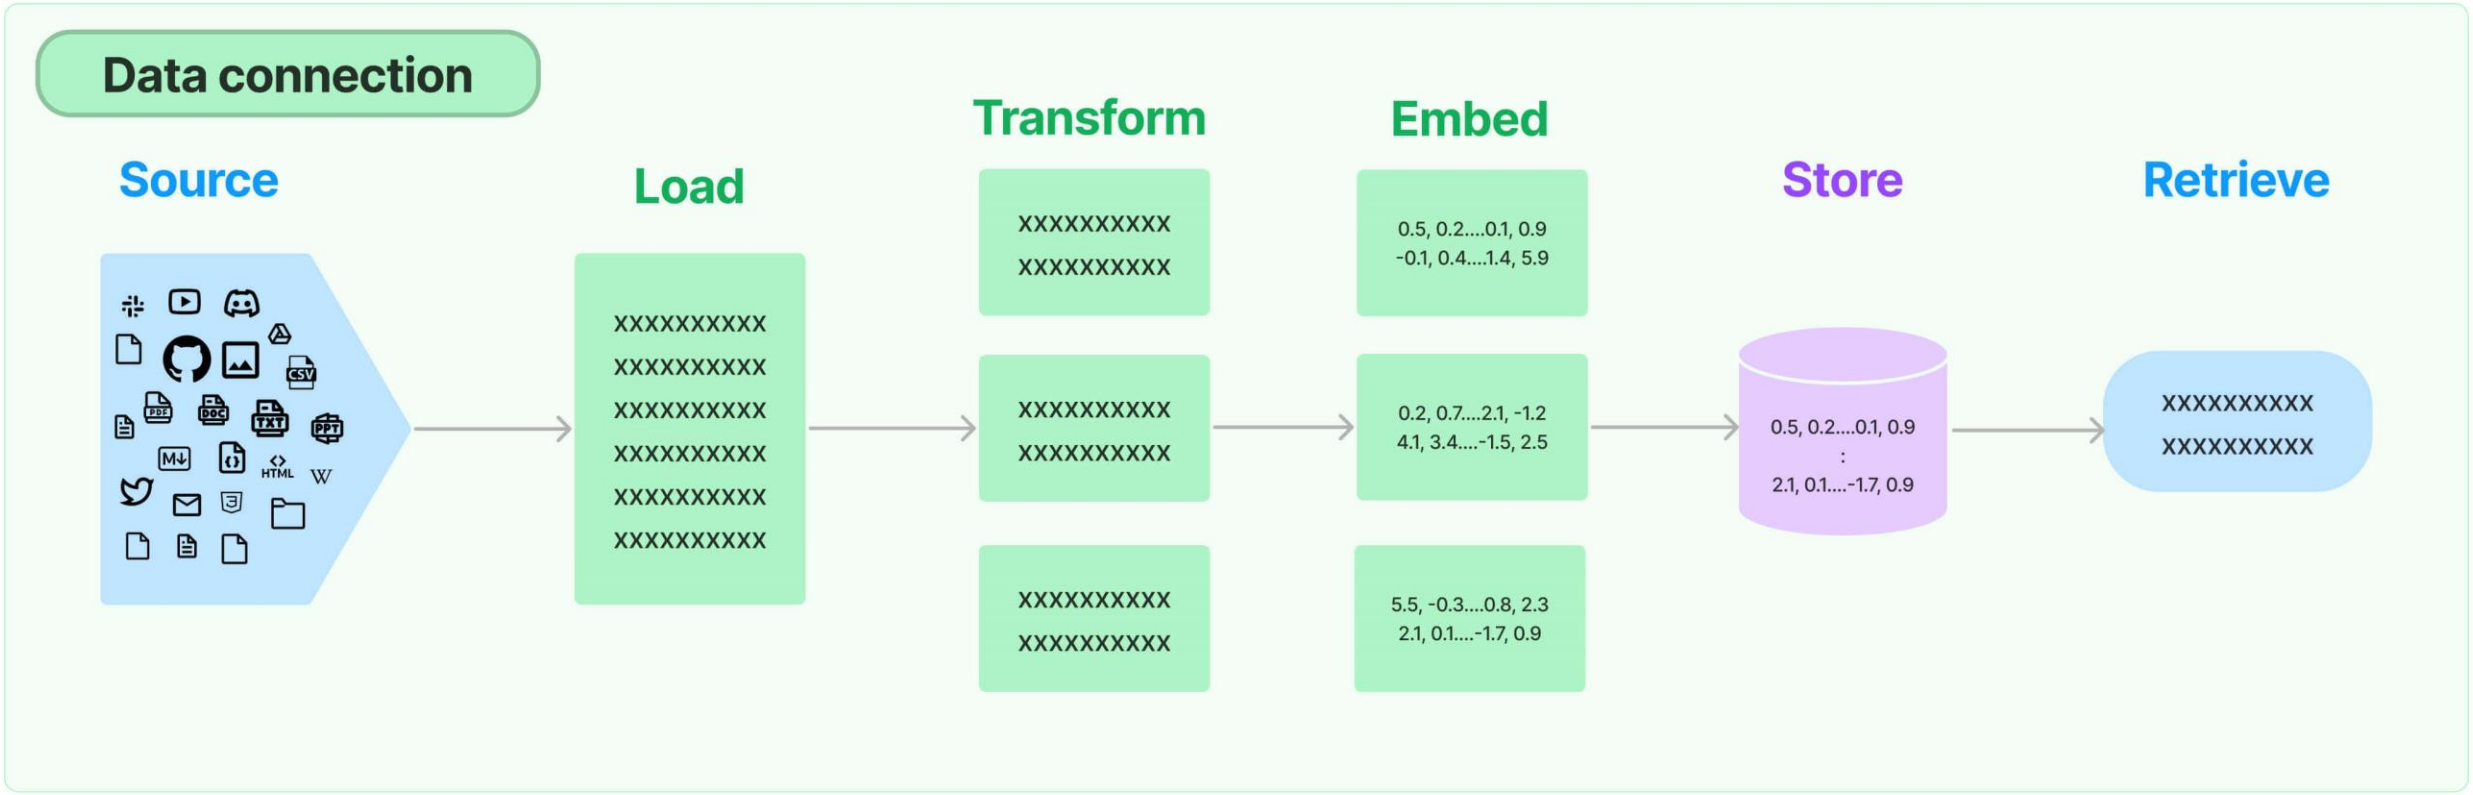


https://python.langchain.com/v0.1/docs/modules/data_connection/

# Retrieval

## Document loader

- Document loader 는 다양한 소스에서 문서를 로드합니다.
- LangChain은 100가지가 넘는 다양한 문서 로더를 제공할 뿐만 아니라 AirByte 및 Unstructured와 같은 다른 주요 공급자와의 통합을 제공합니다.
- LangChain은 모든 유형의 위치(비공개 S3 버킷, 공개 웹사이트)에서 모든 유형의 문서(HTML, PDF, 코드)를 로드할 수 있는 통합 기능을 제공합니다.

## Text Splitting

- 검색의 핵심은 문서에서 관련 부분만 가져오는 것입니다.
- 여기에는 검색을 위해 문서를 준비하기 위한 몇 가지 변환 단계가 포함됩니다.
- 여기서 가장 중요한 것 중 하나는 큰 문서를 작은 덩어리로 분할(또는 청크)하는 것입니다.
- LangChain은 이를 위한 몇 가지 변환 알고리즘과 특정 문서 유형(코드, 마크다운 등)에 최적화된 로직을 제공합니다.

## Text embedding model

- 검색의 또 다른 핵심 부분은 문서에 임베딩을 만드는 것입니다.
- 임베딩은 텍스트의 의미론적 의미를 포착하여 유사한 텍스트를 빠르고 효율적으로 찾을 수 있게 해줍니다.

# Retrieval

## Vector store

- 벡터 스토어는 임베딩의 효율적인 저장과 검색을 지원합니다.
- LangChain은 오픈소스 로컬 스토어부터 클라우드 호스팅 벡터스토어까지 다양한 벡터 스토어와의 통합을 제공합니다.

## Retriever

- 데이터베이스에 저장된 데이터를 검색 합니다.
- LangChain은 다양한 검색 알고리즘을 지원합니다.
- LangChain은 시맨틱 검색을 지원하며, 아래와 같은 성능 향상 알고리즘이 있습니다.
  - Parent Document Retriever: 상위 문서당 여러 개의 임베딩을 생성할 수 있어 작은 청크를 조회할 수 있지만 더 큰 컨텍스트를 반환할 수 있습니다.
  - Self Query Retriever: 사용자 질문에는 단순한 의미론이 아니라 메타데이터 필터로 가장 잘 표현될 수 있는 논리를 표현하는 참조가 포함되어 있는 경우가 많습니다. 자체 쿼리를 사용하면 쿼리에 존재하는 다른 메타데이터 필터로부터 쿼리의 의미론적 부분을 파싱할 수 있습니다.
  - Ensemble Retriever: 여러 다른 소스에서 또는 여러 다른 알고리즘을 사용하여 문서를 검색합니다.

# Retrieval

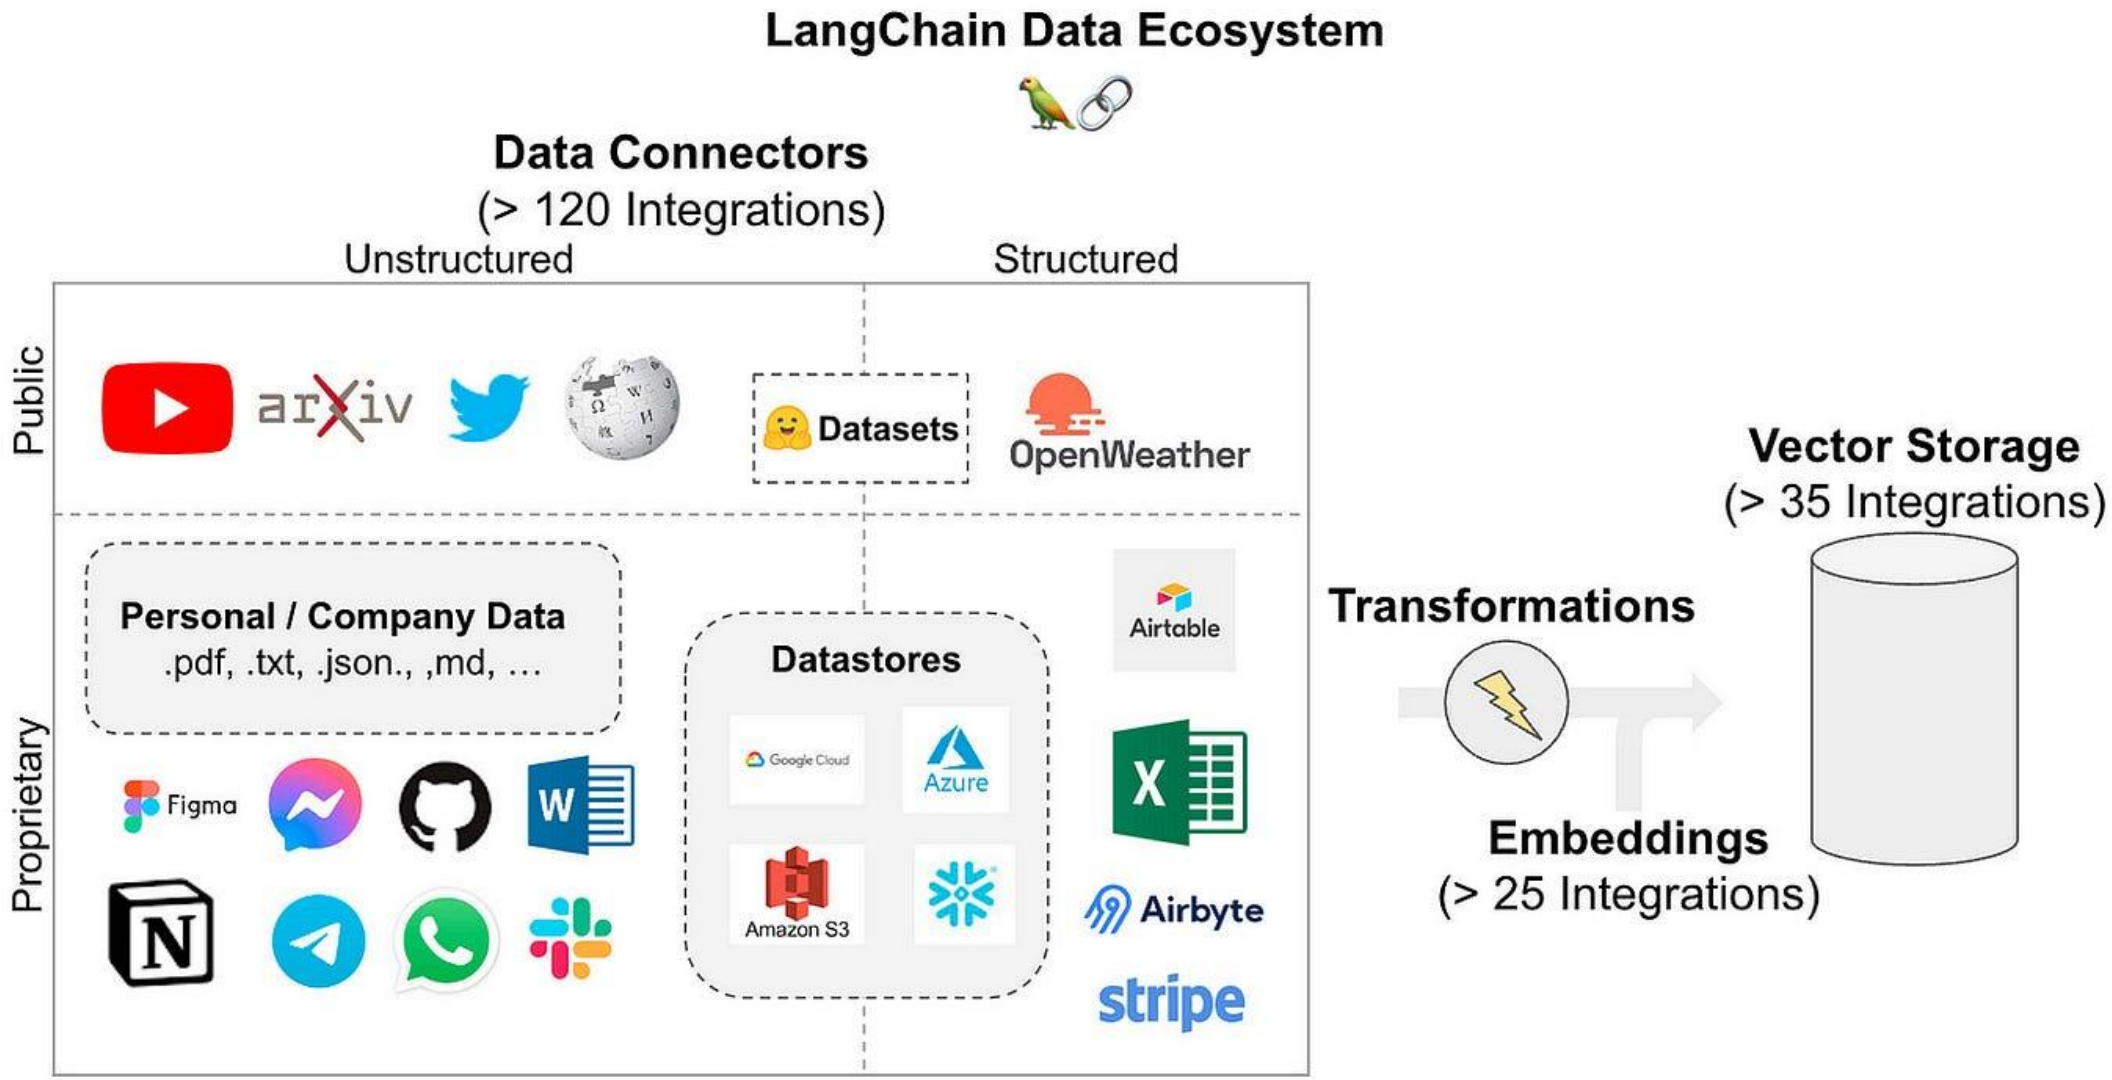


https://nikhilpentapalli.medium.com/langchain-in-detail-6cf8ecfb2464

# Agent

Agent의 핵심 아이디어는 언어 모델을 사용하여 수행할 일련의 작업을 선택하는 것입니다.
에이전트에서는 언어 모델이 추론 엔진으로 사용되어 어떤 작업을 어떤 순서로 수행할지 결정합니다.

## Agent 타입

| Agent Type | Intended Model Type | When to Use | API |
|---|---|---|---|
| Tool Calling | Chat | 도구 호출 모델을 사용하는 경우 | Ref |
| OpenAI Tools | Chat | 최신 OpenAI 모델(1106 이후)을 사용하는 경우 | Ref |
| OpenAI Functions | Chat | OpenAI 모델 또는 함수 호출을 위해 미세 조정된 오픈 소스 모델을 사용 중이며 OpenAI와 동일한 함수 매개 변수를 노출하는 경우 | Ref |
| XML | LLM | Anthropic 모델 또는 XML에 능숙한 다른 모델을 사용하는 경우 | Ref |
| Structured Chat | Chat | 여러 입력이 있는 도구를 지원해야 하는 경우 | Ref |
| JSON Chat | Chat | JSON에 능숙한 모델을 사용하는 경우 | Ref |
| ReAct | LLM | 간단한 모델을 사용하는 경우 | Ref |

https://python.langchain.com/v0.1/docs/modules/agents/agent_types/

# Chain

Chain은 LLM, 도구 또는 데이터 전처리 단계에 대한 호출 시퀀스입니다.

## 기본적인 Chain 구성방법

Chain 을 구성하는 기본적인 방법은 LCEL(LangChain Expression Language )입니다.
| 기호는 서로 다른 구성 요소를 연결하고, 한 구성 요소의 출력을 다음 구성 요소의 입력으로 전달합니다.

```
chain = prompt | model | output_parser
```

LangChain은  LCEL 체인과 레거시 체인을 제공하고 있습니다.

## LCEL Chain 생성자

| Chain Constructor | When to Use |
|---|---|
| create_stuff_documents_chain | 이 체인은 문서 목록을 가져와서 모두 프롬프트로 포맷한 다음 해당 프롬프트를 LLM에 전달합니다. |
| create_openai_fn_runnable | OpenAI 함수 호출을 사용하여 선택적으로 출력 응답을 구조화 하려는 경우. |
| create_structured_output_runnable | OpenAI 함수 호출을 사용하여 LLM이 특정 함수로 응답하도록 강제하려는 경우. |
| load_query_constructor_runnable | 쿼리를 생성하는 데 사용할 수 있습니다. |
| create_sql_query_chain | 자연어로 SQL 데이터베이스에 대한 쿼리를 작성하려는 경우. |
| create_history_aware_retriever | 이 체인은 대화 기록을 가져온 다음 이를 사용하여 검색 쿼리를 생성하고 이를 기본 리트리버에 전달합니다. |
| create_retrieval_chain | 이 체인은 사용자 문의를 받아 리트리버로 전달하여 관련 문서를 가져옵니다. |

https://python.langchain.com/v0.1/docs/modules/chains/

# Memory

LangChain Memory 는 대화 과정에서 발생하는 정보를 저장하고 관리하여,
보다 자연스럽고 지속적인 대화 경험을 제공할 수 있도록 합니다.

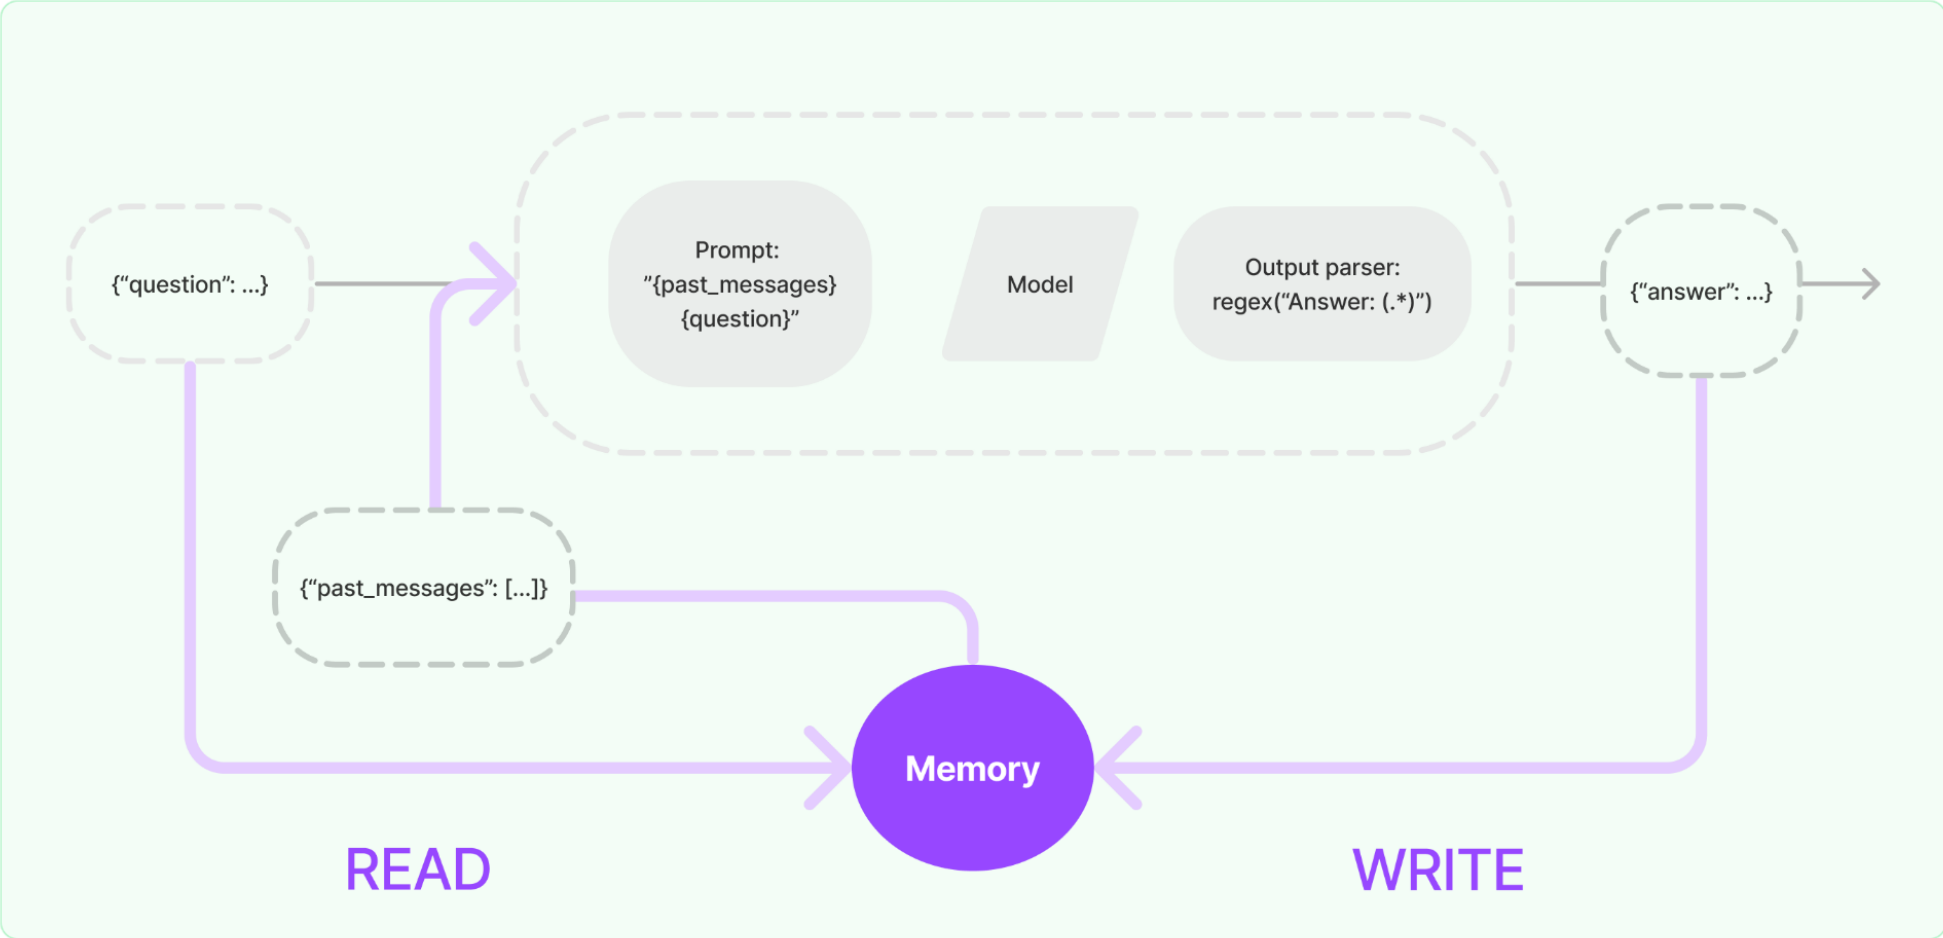


https://python.langchain.com/v0.1/docs/modules/memory/

# LangSmith

https://smith.langchain.com/

LLM 애플리케이션을 개발, 디버깅, 최적화할 수 있도록 도와주는 Observability & Debugging 도구입니다.

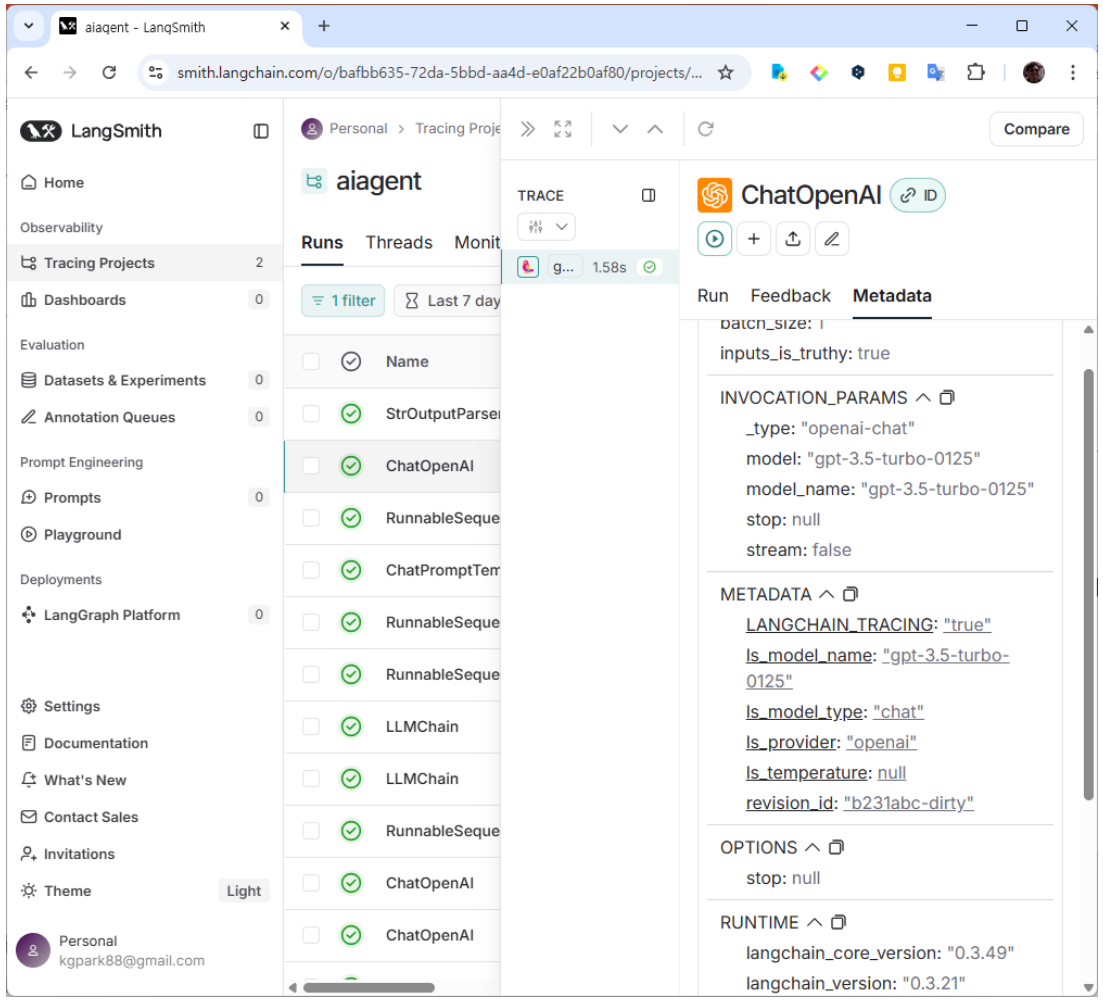


## Observability

- LangSmith에서 Trace를 분석
- 이를 기반으로 메트릭, 대시보드, 알림을 구성

## Evals

- 애플리케이션 생산 트래픽을  평가
- 애플리케이션 성능을 평가하고 데이터에 대한 인적 피드백

## Prompt Engineering

- LangSmith에서 Trace를 분석
- 자동 버전 제어 및 협업 기능을 사용하여 프롬프트를 반복

https://docs.smith.langchain.com/

# LangSmith

## ■ 환경변수 설정

- export LANGSMITH_TRACING=true
  export LANGSMITH_API_KEY="<langsmith-api-key>"
  # OpenAI 사용 경우
  export OPENAI_API_KEY="<your-openai-api-key>"

Python TypeScript

```python
from openai import OpenAI
from langsmith.wrappers import wrap_openai

openai_client = wrap_openai(OpenAI())

# This is the retriever we will use in RAG
# This is mocked out, but it could be anything we want
def retriever(query: str):
    results = ["Harrison worked at Kensho"]
    return results

# This is the end-to-end RAG chain.
# It does a retrieval step then calls OpenAI
def rag(question):
    docs = retriever(question)
    system_message = """Answer the users question using only the provided information below:

    {docs}""".format(docs="\n".join(docs))

    return openai_client.chat.completions.create(
        messages=[
            {"role": "system", "content": system_message},
            {"role": "user", "content": question},
        ],
        model="gpt-4o-mini",
    )
```

https://docs.smith.langchain.com/observability

# LangChain 실습

langchain_basic.ipynb

langchain_component.ipynb

langchain_rag.ipynb

# RAG 파이프라인 구축 실습

langchain_rag_docling_milvus

오픈소스 기술스택

- Docling : https://github.com/docling-project/docling
- LangChain : https://github.com/langchain-ai/langchain
- Milvus : https://github.com/milvus-io/milvus
- HuggingFace : https://huggingface.co/
- Ollama : https://github.com/ollama/ollama
- Langfuse : https://github.com/langfuse/langfuse

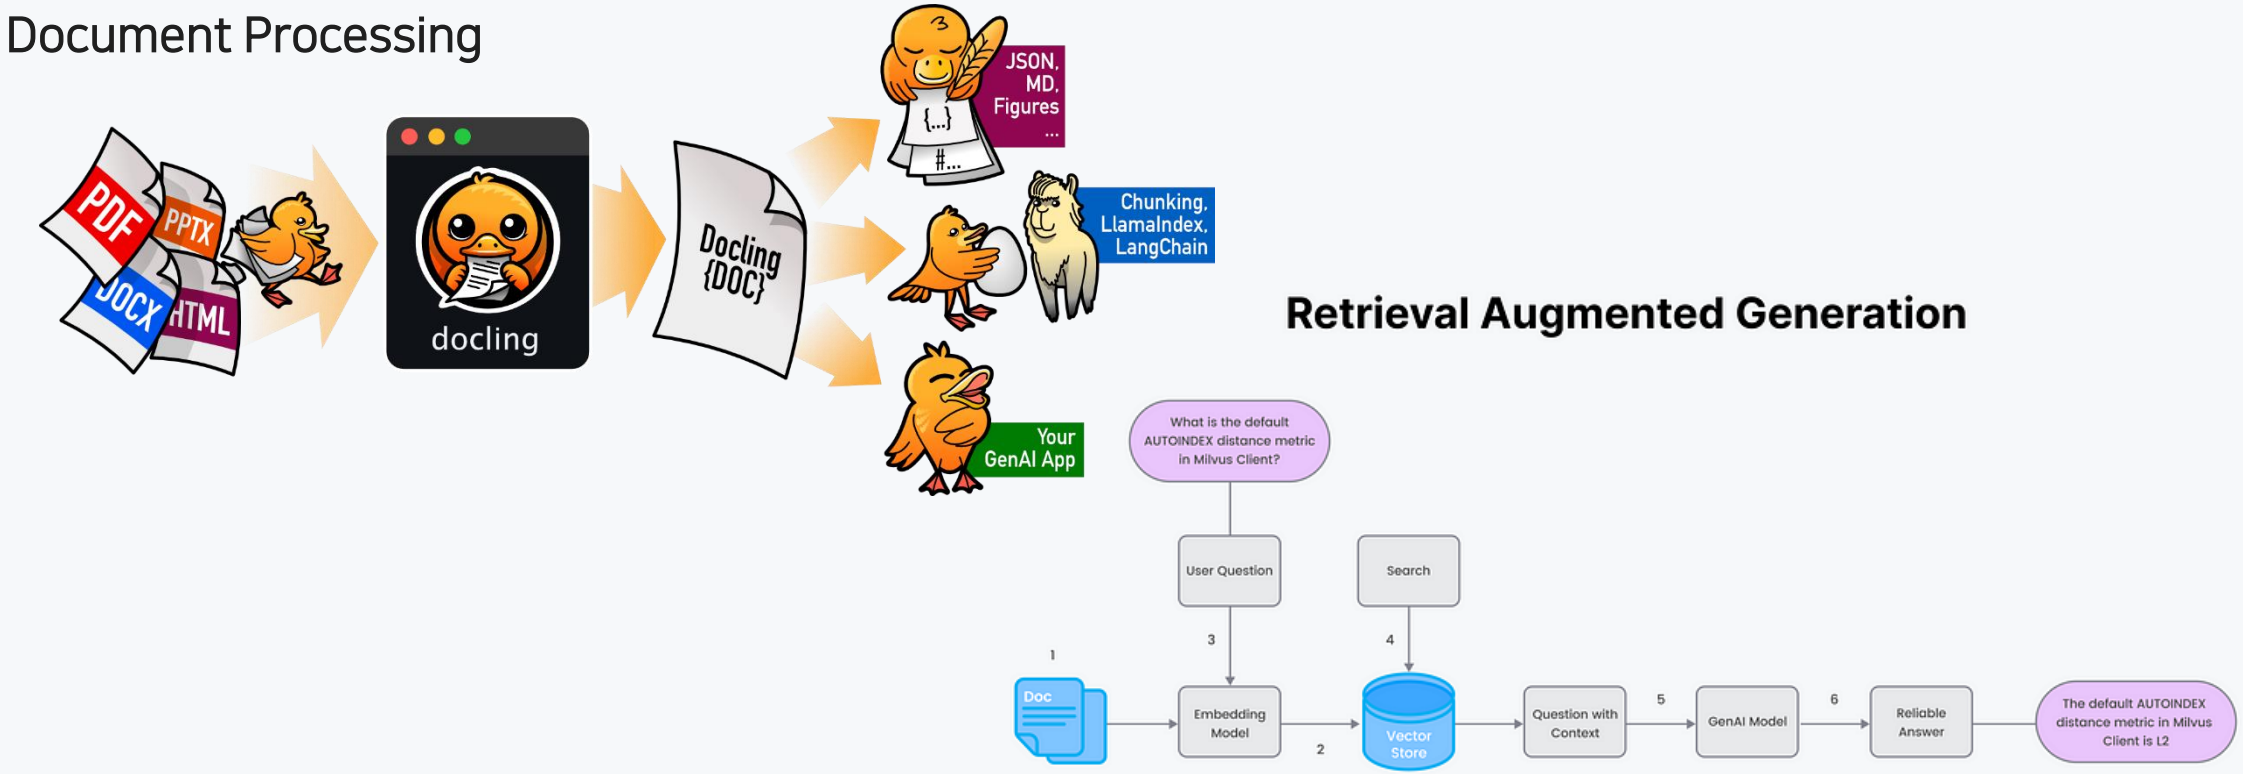

Thank you